Guion de sustentación

Laboratorio 4 · Auditoría Backend IA — Kohem Chemicals

Cómo usar este documento

Es un resumen para estudiar, no un anexo del informe. En 5 minutos cubre qué se auditó, cómo funciona la IA, qué se encontró y qué responder si preguntan.

1. En una frase

«Auditamos el backend del MVP de Kohem Chemicals, en especial el asistente de IA, y verificamos con 12 casos y 75 pruebas que calcula bien los pedidos, valida las entradas, responde con datos reales y separa correctamente sus capas.»

2. Qué es Kohem Chemicals

- Distribuidora de materias primas para cosmética y aseo.
- MVP con FastAPI + SQLite en el backend y React en el frontend.
- Módulo de IA: recibe un mensaje, consulta políticas (RAG), ejecuta herramientas (MCP) y responde con precios y stock reales.
- Arquitectura Onion: dominio, aplicación, infraestructura y presentación.

3. Cómo funciona la IA (lo más importante)

Flujo de un mensaje:

1. El cliente escribe en el chat.
2. El backend busca políticas aplicables (IVA, tope, stock mínimo).
3. Decide la intención: cotizar, consultar stock, asesoría o conversación.
4. Ejecuta herramientas MCP que leen el catálogo y calculan el pedido.
5. Responde con las cifras calculadas por el dominio.

Pieza	Qué hace	En palabras simples
RAG	Recupera políticas de negocio.	Le da las reglas antes de responder.
MCP	Expone catálogo, stock y cotización.	Son las «manos» del asistente.
DeepSeek	Interpreta y redacta (opcional).	Es la voz, no la calculadora.
Dominio	Calcula subtotal, IVA y tope.	Es la calculadora confiable.

Dos modos:

- Asistente (por defecto): respuestas con plantilla, sin depender de internet. Ideal para auditar y para reproducir resultados.
- Conversacional: DeepSeek redacta como asesor comercial usando el catálogo y las cifras reales. Si falla o no hay clave, vuelve solo al modo asistente.

4. Los 12 casos, agrupados

Grupo	Casos	Qué se verificó
Cálculo y reglas	P01–P03	Subtotal, IVA, tope, stock, negativos y decimales.
Contrato y errores	P04, P09	Códigos 200/401/400/415/422, sin 500 ni fugas.
Lenguaje y RAG	P05, P06	Diez formas de pedir, IVA y tope solo cuando aplica.

Integración	P07, P08	MCP real por stdio, pedido, stock y auditoría.
Calidad y motor	P10–P12	75 pruebas, capas limpias, DeepSeek y conversación.

Resultado: los 12 casos cumplen. La suite quedó en 75 pruebas aprobadas y 0 fallos.

5. Hallazgos abiertos (lo que aún se puede mejorar)

ID	Hallazgo	Por qué importa	Recomendación
H-L4-01	La ruta de SQLite depende de la carpeta desde donde se arranca.	Puede crear una base vacía si se ejecuta desde otro lugar.	Usar ruta absoluta o relativa a la raíz.
H-L4-02	La clave JWT tiene un valor por defecto.	Con ese valor se podrían falsificar tokens.	Validarla al arrancar y fallar si es la de ejemplo.
H-L4-03	El servidor MCP no pide autenticación.	Cualquier proceso local puede usar sus herramientas.	Mantenerlo local o añadir token/allowlist.
H-L4-04	El asistente no registra pedidos.	Solo cotiza y consulta stock; el pedido se crea aparte.	Añadir la herramienta registrar_pedido.

6. Preguntas probables y respuestas cortas

¿¿Es una IA real?
Sí, opcional. Con clave usa DeepSeek para interpretar y redactar; sin clave funciona con reglas. Las cifras nunca las inventa el modelo: las calcula el dominio.

¿¿Por qué no usa siempre el modelo?
Por costo, latencia y reproducibilidad. La auditoría necesita resultados estables; el modo asistente los garantiza.

¿¿Qué es MCP?
Un protocolo para exponer herramientas. Aquí hay tres: listar materiales, consultar stock y calcular pedido, y se probó también por transporte stdio.

¿¿Qué es RAG?
Recuperar información antes de responder. En este MVP es un adaptador simulado que busca políticas por palabras clave, no embeddings.

¿¿Cómo evitan que invente precios?
El modelo recibe un bloque de datos ya calculado y se le prohíbe inventar. Las cifras salen de la base y del dominio.

¿¿Qué pasa si DeepSeek falla?
Se devuelve la respuesta del modo asistente; el chat sigue funcionando.

¿¿Por qué solo 4 hallazgos?
Porque los otros casos cumplen. Los cuatro abiertos son de endurecimiento (seguridad, rutas) o de alcance (registrar pedidos).

¿¿Qué mejorarían primero?
La clave JWT y la ruta de la base, por impacto; luego la autenticación del MCP y la herramienta de pedidos.

¿¿Cómo probaron todo?
12 scripts con evidencia JSON, 75 pruebas automatizadas y revisión de imports por capas.

¿¿Qué no cubre?
Frontend, pruebas de carga, RAG con embeddings y registro de pedidos desde el chat.

7. Guion sugerido de 5 minutos

Tiempo	Qué decir
0:00–0:40	Qué es Kohem y qué se auditó: módulo de IA del backend.
0:40–1:40	Arquitectura y flujo: RAG → intención → MCP → dominio → respuesta.
1:40–3:00	Casos y resultados: 12 casos, 75 pruebas, 0 fallos.
3:00–4:10	Demo: Swagger /docs → «¿Qué venden?» y «2 kg de glicerina».
4:10–5:00	Hallazgos y cierre: 4 abiertos, recomendaciones y alcance.

8. Qué mostrar en pantalla

- Swagger en http://127.0.0.1:8000/docs, endpoint POST /api/v1/ai/chat.
- Pregunta «¿Qué venden?»: el asistente lista los materiales reales.
- Pregunta «Quiero 2 kg de glicerina»: respuesta con subtotal y total.
- Salida de pytest: 75 passed.
- Carpeta docs/laboratorio4/evidencias: JSON de cada caso.

9. Glosario mínimo

- LLM: modelo de lenguaje; aquí DeepSeek, opcional.
- RAG: recuperación de información para fundamentar la respuesta.
- MCP: protocolo de herramientas; conecta el asistente con catálogo y cálculo.
- Onion: arquitectura por capas, con el dominio en el centro.
- Fallback: respaldo automático cuando el modelo no responde.

10. Frase de cierre

«El backend quedó auditado y funcional: calcula con reglas verificables, responde con datos reales y puede conversar con DeepSeek sin perder el control de las cifras. Las mejoras pendientes están identificadas y priorizadas.»